

APPRENTISSAGE STATISTIQUE

CHAPITRE 0

January 7, 2023

- 1 Présentation du cours
- 2 Data Science
- 3 Machine Learning (Apprentissage Automatique)
- 4 Les différents types d'apprentissage automatique

- ① Enseignant
- ② Volume horaire : 40 heures
- ③ Préalables
- ④ Travaux pratiques
- ⑤ Travaux Dirigés
- ⑥ Evaluations

- ➊ Introduction à la data science
- ➋ Introduction au Machine Learning
- ➌ Évaluation de modèles
- ➍ Régression Linéaire
- ➎ Modèles linéaires généralisés
- ➏ Apprentissage non supervisé
- ➐ Support Vector Machine
- ➑ ...

- 1 Présentation du cours
- 2 Data Science**
- 3 Machine Learning (Apprentissage Automatique)
- 4 Les différents types d'apprentissage automatique

La data science est un nouveau domaine de travail, qui augmente les capacités d'analyse classique, afin d'aider les entreprises à prendre des décisions informées. Elle s'appuie pour cela sur des données utiles et ne peut s'appliquer que dans certaines problématiques précises.

La data science (ou science des données en français) et le machine learning (ou apprentissage automatique) sont deux mots très en vogue lorsque l'on parle de la révolution Big Data, de prédiction des comportements ou tout simplement de la transformation numérique des entreprises. Et comme pour tous les domaines innovants, il est parfois difficile de s'y repérer.

Qu'est-ce que la data science ?

Le premier objectif du data scientist est de produire des méthodes (automatisées, autant que possible) de tri et d'analyse de données, afin d'en extraire des informations utiles.

Le besoin d'un data scientist est apparu pour trois raisons principales :

- ❶ l'explosion de la quantité de données produites et collectées par les humains ;
- ❷ l'amélioration et l'accessibilité plus grande des algorithmes de traitement des données ;
- ❸ l'augmentation exponentielle des capacités de calcul des ordinateurs.

*Deux composantes sont nécessaires avant de se demander si la data science peut, oui ou non, apporter de la valeur et aider à la résolution d'un problème : **des données et une problématique bien définie.***

- les données constituent la ressource principale pour qu'un data scientist puisse effectuer son travail correctement
 - ① récupérer des données liées au problème que vous cherchez à résoudre
 - ② les données ne sont pas toujours utilisables d'un point de **vue éthique ou pour des raisons de sécurité.**
 - ③ **"cold start problem"** : situation où l'on commence sans données.

Il existe un spectre assez large de problématiques que l'on peut résoudre en data science. Mais vous pouvez aussi facilement en exclure un certain nombre, surtout si vous vous trouvez dans un milieu d'entreprise, avec des contraintes de temps fortes pour produire des résultats.

- ❶ **Estimer la faisabilité d'un projet est toujours compliqué en data science**
- ❷ *Une manière de préciser cette problématique en milieu professionnel, c'est de passer par **une phase de prototypage** qui permet de tester la viabilité et la solidité du projet. Créer un prototype permet rapidement de détecter s'il y a une opportunité car les plus gros obstacles sont écartés : la récupération des données, la formulation du problème à résoudre, une estimation des coûts nécessaires, les difficultés d'implémentation hardware ou software, etc.*

Exemple

- *Prédire les ventes d'une campagne marketing.*
- *Identifier si une image est déjà présente dans une banque d'image existante.*
- *Segmenter les utilisateurs d'un site en plusieurs groupes en fonction de leur comportement sur le site.*
- *Dire si une phrase est humoristique ou pas.*

Data Science et analyse de données


- 1 Le machine learning se distingue dans un premier temps par l'approche utilisée pour résoudre la problématique - **la notion d'apprentissage** - que l'on va étudier dans la suite de ce cours
- 2 L'analyse de données ("data analysis"), elle, utilise des méthodes issues des statistiques classiques comme les estimateurs, les analyses de corrélations ou encore la régression linéaire.
- 3 Pour le data scientist, l'objectif est d'aller plus loin dans les algorithmes d'analyse afin d'obtenir un degré supérieur d'information, notamment grâce au machine learning.
- 4 Dans l'exemple ci-dessous, on représente le risque de désabonnement de clients selon deux critères, Drivers A et Drivers B. Là où une analyse de données statistiques classique (la courbe) nous donne simplement une frontière de classification, on voit qu'un algorithme de machine learning (les isobares) peut aller beaucoup plus loin et dépasser les contraintes de linéarité pour fournir une réponse plus précise, avec une carte de risques.

Classic regression analysis



Isobar graph facilitated by machine learning: warmer colors indicate higher degrees of risk

Drivers: A



Travail du data scientist

Le machine learning ne désigne en réalité qu'une partie du travail d'un data scientist

Le cycle de travail du data scientist peut se résumer par le schéma ci-dessous :




Figure: Cycle de travail du data scientist

- ➊ **Récupération des données.** Les bases de données existantes, des données brutes alternatives (image, son, etc.), et même la création de nouveaux canaux d'acquisition de données. Essayez de trouver l'ensemble des variables qui impactent de près ou de loin le phénomène qui vous intéresse
- ➋ **Nettoyage des données :** s'assurer qu'elles sont consistantes, sans valeurs aberrantes ni manquantes.
- ➌ **Exploration des données :** cette étape vous permet de mieux comprendre les différents comportements et de bien saisir le phénomène sous-jacent.
- ➍ **Modélisation des données à l'aide du machine learning :** la création du modèle statistique associé aux données qui nous intéressent ! C'est ce qu'on appelle le machine learning (ou apprentissage automatique).

- 1 **Évaluation et interprétation des résultats** : Une fois un premier travail de modélisation effectué, la suite de l'étude s'effectue par l'évaluation de la qualité de notre modèle, c'est-à-dire sa capacité à représenter avec exactitude notre phénomène, ou a minima sa capacité à résoudre notre problématique.
- 2 **Mise en production du modèle** : Une fois qu'on est satisfait de la qualité des performances de notre modèle, on va pouvoir passer à l'étape suivante, qui est le rendu de nos résultats et le potentiel déploiement du modèle en production.

Au sein du cycle de travail du data scientist, le machine learning désigne l'ensemble des méthodes de modélisation statistique à partir des données.

- 1 Présentation du cours
- 2 Data Science
- 3 Machine Learning (Apprentissage Automatique)**
- 4 Les différents types d'apprentissage automatique

- ❶ Le problème de machine learning constitue l'étape suivante et permet à un ordinateur de modéliser les données qui lui sont fournies.
- ❷ "Modéliser" signifie dans ce cas représenter le comportement d'un phénomène, afin de pouvoir aider à la résolution d'un problème concret de l'entreprise

En machine learning, l'algorithme se construit une "représentation interne" afin de pouvoir effectuer la tâche qui lui est demandée (prédiction, identification, etc.). Pour cela, il va d'abord falloir lui entrer un jeu de données d'exemples afin qu'il puisse **s'entraîner** et s'améliorer, d'où le mot **apprentissage**.




Figure: Un détail des deux phases du process de machine learning

Le machine learning est l'apprentissage d'un modèle statistique par la machine grâce à des données d'entraînement. Un problème de machine learning comporte plusieurs éléments spécifiques : :

- ① les données** (les données d'entraînement mais aussi les nouvelles données) ;
- ② la tâche à accomplir** (prédire, recommander, décider quelque chose, etc.) ;
- ③ l'algorithme d'apprentissage;**
- ④ l'analyse d'erreur (ou mesure des performances du modèle).**

- ❶ **Les base de données** : les bases de données constituent la source principale de récupération de données par les data scientists. Ces bases de données peuvent comprendre différents types d'information, une bonne partie généralement spécifique à l'activité de l'entreprise.
- ❷ **Les données brutes** : Le **deep learning** regroupe les algorithmes et modèles assez gros et complexes pour pouvoir traiter les données brutes directement, sans pré-traitement.
- ❸ **Le Texte** : articles, livres, messages, etc ...
Le traitement du texte (appelé **NLP** comme **Natural Language Processing**) constitue un domaine de recherche à part entière.
- ❹ **Les images (et vidéos)** : Les images sont aussi une des sources de captation de l'environnement souvent utile sur des problématiques d'entreprise. Beaucoup d'entreprises ont des banques d'images à traiter pour les classer par type ou autre.
Le traitement des images et vidéos constitue un domaine de recherche à part entière (**computer vision en anglais**).

La tâche spécifique à accomplir correspond au problème qu'on cherche à résoudre grâce à la modélisation du phénomène.

- les **recommandations** de produits
- l'**identification** de transactions frauduleuses
- la **prédiction** de l'impact d'une campagne marketing sur le taux de conversion
- la **prédiction** du prix optimal d'un produit pour maximiser le nombre de ventes.

L'algorithme d'apprentissage

L'algorithme d'apprentissage constitue la méthode avec laquelle le modèle statistique va se paramétrer à partir des données d'exemple. Il existe de nombreux algorithmes différents ! On choisira un type d'algorithme particulier en fonction du type de tâche que l'on souhaite accomplir et du type de données dont on dispose. En gros, quelle est l'entrée de l'algorithme et quelle est la sortie.

- ❶ la régression linéaire
- ❷ K-nn (K-nearest neighbors algorithm)
- ❸ les Support Vector Machine (SVM)
- ❹ les random forests.
- ❺ etc ...

Mesurer les performances fait partie intégrante du travail de modélisation. Il faut en général déterminer une mesure principale, souvent spécifique à la tâche à accomplir. Le choix de cette métrique est très important !

Exemple

Considérons un algorithme de détection de fraudes bancaires. On peut mesurer la performance de l'algorithme en :

- mesurant la proportion totale de transactions détectées comme fraude. Cependant, on compte ici les transactions qui ne sont pas des fraudes et qui ont quand même été notées comme en étant (appelé "faux positifs").
- précisant la proportion de "vraies fraudes" détectées par rapport au total de transactions détectées comme frauduleuses.

- 1 Présentation du cours
- 2 Data Science
- 3 Machine Learning (Apprentissage Automatique)
- 4 Les différents types d'apprentissage automatique**

Une première grande distinction à faire en machine learning est la différence entre apprentissage **supervisé** et **non supervisé**. En anglais, ces deux notions se nomment respectivement supervised learning et unsupervised learning.

Supposons que nous avons une base de photos à catégoriser.

- 1 En **apprentissage supervisé**, vous allez récupérer des données dites annotées de leurs sorties pour entraîner le modèle, c'est-à-dire que vous leur avez déjà associé un label ou une classe cible et vous voulez que l'algorithme devienne capable, une fois entraîné, de prédire cette cible sur de nouvelles données non annotées.
- 2 En **apprentissage non supervisé**, les données d'entrées ne sont pas annotées. Comment cela peut-il fonctionner ? L'algorithme d'entraînement s'applique dans ce cas à trouver seul les similarités et distinctions au sein de ces données, et à regrouper ensemble celles qui partagent des caractéristiques communes.

supervised learning et unsupervised learning

Une représentation un peu plus mathématique pour vous permettre d'éclaircir le concept :

- En **supervised learning**, on reçoit des données d'exemple annotées : $(x_1, y_1), (x_2, y_2), (x_3, y_3), \dots$ et on espère prédire la sortie sur de nouvelles observations : $x^* \rightarrow y^*$
- En **unsupervised learning**, on reçoit uniquement des observations brutes de variables aléatoires : $x_1, x_2, x_3, x_4, \dots$ et on espère découvrir la relation avec des variables latentes structurelles : $x_i \rightarrow y_i$

Il existe en fait deux autres familles d'algorithmes que nous ne détaillerons pas

- **le semi-supervised learning**, qui prend en entrée certaines données annotées et d'autres non.
- **le reinforcement learning**, qui se base sur un cycle d'expérience/récompense et améliore les performances à chaque itération.

Régression ou Classification

Une autre distinction qui vous aidera dans le choix d'un algorithme de machine learning est le type de sortie que l'on attend de notre programme : est-ce une valeur **continue** (un nombre réel) ou bien une valeur **discrète** (une catégorie) ? Le premier cas est appelé une **régression**, le second une **classification**.




Figure: Illustration de la différence entre classification linéaire et régression linéaire

Beaucoup d'algorithmes permettent en réalité d'effectuer ces deux types de tâches. Être vigilant sur le type de tâche à réaliser permet cependant de structurer son approche et est à prendre en compte comme une contrainte supplémentaire dans la construction du modèle.

Demandez-vous donc toujours si vous avez affaire à un problème de régression ou de classification.

Il existe aussi un autre type de prédiction possible qui est de sortir plusieurs labels de manière ordonnée (machine-learned ranking en anglais). Par exemple, l'algorithme PageRank de Google retourne des résultats de recherche dans l'ordre, du plus pertinent au moins pertinent.

- ❶ Récupération de données ([kaggle](#), ou [github](#) etc ...)
- ❷ Nettoyage et l'exploration des données (En Python, l'écosystème Scipy est universellement utilisé avec ses librairies : Pandas, numpy, matplotlib, etc ...)
- ❸ Modélisation et évaluation : [Scikit-Learn](#) et Tensorflow

Bibliographie

- ① Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani. *An Introduction to Statistical Learning : with Applications in R*. New York : Springer, 2014.
- ② Azencott Chloé-Agathe. *Introduction au Machine Learning*. Paris :Dunod, 2019.
- ③ Trevor Hastie, Robert Tibshirani, Jerome Friedman. *The Elements of Statistical Learning Data Mining, Inference, and Prediction*. 2nd ed. New York : Springer, 2009.
- ④ Ethem Alpaydin, *Introduction to Machine Learning*, MIT Press, 3e édition, 2014, ISBN : 978-0262028189.
- ⑤ Marc Peter Deisenroth, A. Aldo Faisal, Cheng Soon Ong. *Mathematics for machine learning*. Cambridge University Press, 2019.

- 1 Une entreprise veut prédire le prix d'un plein de carburant, connaissant les caractéristiques d'une voiture. Est-ce un problème de régression ou de classification ?
- 2 J'ai une grande banque de textes que je veux catégoriser automatiquement par thématique. Aucun des documents n'a de thématique associée pour le moment. Comment vais-je entraîner mon modèle ?
- 3 En effectuant une tâche de catégorisation sur mes textes, suis-je en train d'effectuer une régression ou une classification ?